

RAPPORT DE PROJET - DEEP LEARNING

Systeme d'aide au tri radiologique

*Classification multi-label, détection d'anomalies et multimodalité image + texte
appliquées aux radiographies thoraciques*

Auteurs

Gloria AMINI

Khanh TA

Colombe MADOUNGOU MOUNDOUBI

Sommaire

1. Problème
2. Données
3. Analyse exploratoire
4. Préparation des données
5. Modélisation supervisée
6. Détection d'anomalies
7. Modélisation multimodale
8. Évaluation
9. Suivi expérimental avec MLflow
10. Démonstrateur applicatif
11. Analyse critique
12. Conclusion et perspectives

1. Problème

1.1 Contexte et objectif métier

La radiographie thoracique est l'examen d'imagerie le plus pratiqué au monde. Le volume d'acquisitions, conjugué à la tension sur le temps de lecture des radiologues, crée un besoin d'outils capables d'assister l'organisation du flux de lecture plutôt que de poser un diagnostic. Nous concevons un système d'aide au tri radiologique dont la finalité est de hiérarchiser les radiographies potentiellement pathologiques, de signaler les cas atypiques, et d'exploiter le contexte textuel lorsqu'un compte-rendu est disponible.

L'objectif métier n'est pas de remplacer l'expertise médicale, mais de fournir une priorisation et une seconde lecture indicative, mise à disposition via un démonstrateur testable.

1.2 Problématique en intelligence artificielle

La problématique se décompose en trois sous-problèmes complémentaires :

1. **Classification supervisée multi-label** de 14 pathologies thoraciques à partir de l'image (un vecteur de probabilités indépendantes par pathologie).
2. **Détection d'anomalies** par reconstruction (autoencodeur), pour repérer les images s'écartant des cas normaux.
3. **Multimodalité image + texte** : exploiter le compte-rendu radiologique en complément de l'image.

1.3 Intérêt du tri radiologique

- Réduire le délai de prise en charge des examens urgents en remontant les cas suspects en tête de lecture.
- Homogénéiser le flux de travail et apporter un filet de sécurité sur les cas atypiques.
- Servir de support pédagogique et de démonstrateur de bout en bout.

1.4 Limites éthiques et médicales

Ce travail est un prototype étudiant à visée pédagogique. Il ne constitue pas un dispositif médical et ne doit pas être utilisé pour un diagnostic : volumétrie limitée, labels partiellement bruités, absence de validation clinique, et risque de faux négatifs. Le démonstrateur affiche explicitement cet avertissement.

2. Données

2.1 Jeu principal : ChestMNIST / ChestMNIST+

La classification supervisée repose sur ChestMNIST / ChestMNIST + (collection MedMNIST, dérivée de NIH ChestX-ray14) : tâche multi-label sur 14 pathologies, avec

splits officiels train / validation / test et plusieurs résolutions (28, 64, 128, 224 px). Nous avons travaillé en 64 px pour les CNN et l'autoencodeur, et en 224 px pour le ViT pré-entraîné.

Les 14 pathologies cibles :

Label (dataset)	Traduction	Label (dataset)
Atelectasis	Atélectasie	Pneumothorax — Pneumothorax
Cardiomegaly	Cardiomégalie	Consolidation — Condensation
Effusion	Épanchement pleural	Edema — Œdème pulmonaire
Infiltration	Infiltrat	Emphysema — Emphysème
Mass	Masse	Fibrosis — Fibrose
Nodule	Nodule	Pleural_Thickening — Épaississement pleural
Pneumonia	Pneumonie	Hernia — Hernie

Tableau 1 - Les 14 pathologies thoraciques du jeu ChestMNIST.

2.2 Jeu multimodal : OpenI / IU X-Ray

Pour la composante image + texte, le jeu retenu est OpenI (IU X-Ray), qui associe des radiographies à de vrais comptes-rendus radiologiques, dans un volume restreint adapté à une preuve de concept. Les labels y sont « faibles » (extraits du texte par mots-clés), donc bruités par construction.

2.3 Justification des choix et jeux écartés

- **ChestMNIST (obligatoire)** : labels propres, splits officiels, résolutions adaptables au matériel.
- **OpenI (multimodal)** : vrais comptes-rendus appariés aux images, volume adapté à une preuve de concept.
- **NIH ChestX-ray14 écarté comme source textuelle** : ses rapports ont servi à générer des labels mais ne sont pas exploitables pour une vraie multimodalité image + compte-rendu.
- **MIMIC-CXR écarté** : plus riche mais contraintes d'accès trop fortes pour le périmètre du projet ; conservé en perspective.

3. Analyse exploratoire

L'analyse exploratoire (script `eda_chestmnist.py`) porte sur les trois splits officiels : 78 468 images d'entraînement, 11 219 de validation et 22 433 de test.

3.1 Distribution et déséquilibre des classes

Le jeu est fortement déséquilibré et multi-label : en moyenne 0,72 pathologie positive par image, et environ 54 % des images ne portent aucune pathologie (42 405 sur 78

468 en entraînement). La pathologie la plus fréquente est l'infiltrat (17,7 %), suivie de l'épanchement (11,8 %) et de l'atélectasie (10,8 %) ; la plus rare est la hernie (0,18 %, soit 144 images), devant la pneumonie (1,25 %) et la fibrose (1,5 %). Ce déséquilibre conditionne tous les choix ultérieurs (pondération de la perte, métriques macro, optimisation du seuil).




Figure 1 - Distribution des 14 pathologies (split d'entraînement).

3.2 Cooccurrences de pathologies

La nature multi-label se traduit par des cooccurrences fréquentes (par exemple épanchement et atélectasie), ce qui justifie un traitement multi-label plutôt que mono-classe.




Figure 2 - Matrice de cooccurrence des pathologies (entraînement).

3.3 Exemples visuels




Figure 3 - Exemples de radiographies annotées de leurs pathologies.

4. Préparation des données

4.1 Traitement des images

- **Redimensionnement** à la résolution cible (64 px pour CNN/ResNet/autoencodeur, 224 px pour le ViT pré-entraîné).
- **Conversion en 3 canaux** : les radiographies en niveaux de gris sont dupliquées sur 3 canaux pour être compatibles avec les modèles pré-entraînés sur ImageNet.
- **Normalisation ImageNet** : moyenne (0.485, 0.456, 0.406), écart-type (0.229, 0.224, 0.225).
- **Augmentation à l'entraînement uniquement** : retournement horizontal, légère rotation et transformation affine. Validation et test ne subissent aucune augmentation.

4.2 Représentation des labels et fonction de perte

Chaque image est représentée par un vecteur binaire de dimension 14, avec une activation sigmoïde par pathologie et une perte BCEWithLogitsLoss. Pour compenser le déséquilibre, un poids `pos_weight` par classe (proportionnel au ratio négatifs/positifs) renforce le poids des pathologies rares.

4.3 Stratégie anti-fuite et reproductibilité

- **ChestMNIST** : splits officiels train/val/test, sans recouvrement.
- **Autoencodeur** : entraîné uniquement sur les images sans aucune pathologie.

- **Reproductibilité** : graine fixée à 42 (Python, NumPy, PyTorch), sauvegarde du meilleur modèle, configuration journalisée dans MLflow.

4.4 Préparation du texte (OpenI)

Les comptes-rendus radiologiques sont tokenisés avec le tokenizer de DistilBERT, avec troncature et remplissage à une longueur maximale de 256 tokens. Pour l'entraînement multimodal, un poids `pos_weight` par classe, borné dans l'intervalle $[1, 20]$, limite l'effet des pathologies extrêmement rares. La séparation train/validation d'OpenI est aléatoire (80 / 20) à graine fixe ; en l'absence d'identifiant patient exploité, un split strictement par patient est recommandé pour éliminer tout risque de fuite.

5. Modélisation supervisée

Trois familles d'architectures profondes sont comparées, conformément au cahier des charges.

5.1 CNN simple entraîné de zéro (baseline)

Trois blocs convolutifs (32, 64, 128 filtres : Conv 3×3, BatchNorm, ReLU, MaxPool), puis pooling moyen adaptatif, Dropout 0.3 et couche linéaire vers 14 sorties.

Justification : illustre les briques du cours — convolution, pooling, BatchNorm, ReLU, Dropout. Léger et rapide, il fournit une baseline de référence pour mesurer l'apport du transfert.

5.2 CNN pré-entraîné : ResNet18 (transfer learning)

ResNet18 pré-entraîné sur ImageNet, dernière couche remplacée par une couche linéaire vers 14 classes. Justification : les connexions résiduelles (skip connections) évitent la disparition du gradient; le transfert d'apprentissage réutilise des représentations bas niveau, précieux sur un jeu médical de taille limitée.

5.3 Vision Transformer (ViT-B/16)

Le ViT découpe l'image en patches 16×16, ajoute un token [CLS] et applique des couches d'auto-attention (résolution 224 px requise pour les poids pré-entraînés). Justification et limites : l'auto-attention capture des dépendances globales, mais le ViT est gourmand en données et sous-performe sur un petit jeu médical, ce que nos résultats confirment.

5.4 Protocole d'entraînement

- **Optimiseur** : AdamW, lr 1e-4, weight decay 1e-4.
- **Perte** : BCEWithLogitsLoss avec `pos_weight`.
- **Planificateur / arrêt** : ReduceLROnPlateau et early stopping (patience 5).
- **Sélection** : average precision macro sur la validation ; meilleur checkpoint conservé.

- **Seuil de décision** : optimisé sur la validation par balayage F1 macro.

5.5 Configuration matérielle et d'entraînement

Matériel : Google Colab, GPU NVIDIA T4. Réglages effectifs par modèle (jeu complet) :

Modèle	Résolution	Époques	Batch	Pré-entraîné
CNN simple	64 px	10	64	non (de zéro)
ResNet18	64 px	10	64	oui (ImageNet)
ViT-B/16	224 px	1	32	oui (ImageNet)

Tableau 2 - Configuration d'entraînement des trois architectures.

Note : le ViT n'a été entraîné qu'une époque en raison du coût de calcul à 224 px ; ses performances reflètent donc à la fois sa nature gourmande en données et cet entraînement limité.

6. Détection d'anomalies

6.1 Architecture et protocole

Autoencodeur convolutif : encodeur à 4 convolutions à pas 2 (32→256 filtres), décodeur symétrique à convolutions transposées, sortie sigmoïde.

- **Apprentissage « normal uniquement »** : entraîné seulement sur les images sans pathologie (8 époques, 64 px).
- **Score d'anomalie** : erreur de reconstruction MSE moyenne par image.
- **Seuil** : 95e percentile des erreurs des images normales de validation.
- **Évaluation** : tâche binaire « aucune pathologie » vs « au moins une pathologie ».

6.2 Résultats

Sur le test, l'autoencodeur obtient un ROC-AUC de 0,485 et une average precision de 0,459, pour un F1 de 0,087 (précision 0,446, rappel 0,048). Ces valeurs, proches du hasard pour le ROC-AUC, montrent que l'erreur de reconstruction ne sépare pas efficacement les radiographies pathologiques des radiographies normales dans ce cadre.




Figure 4 - Distribution des scores d'anomalie (normaux vs pathologiques) sur le test.




Figure 5 - Reconstructions de l'autoencodeur (validation).

6.3 Interprétation et limites

Ce résultat est cohérent avec la nature du problème : de nombreuses pathologies thoraciques se traduisent par des modifications locales et subtiles que l'autoencodeur apprend aussi à reconstruire, tandis que la notion de « normal » reste très hétérogène. Le score est par ailleurs non spécifique (il signale un écart, pas une pathologie précise) et sensible au seuil. La détection d'anomalies par reconstruction constitue donc ici un signal faible, à interpréter avec prudence et sans portée clinique.

7. Modélisation multimodale

7.1 Représentations et stratégie de fusion

La brique multimodale combine une représentation image (embedding ResNet18, 512) et une représentation texte (token [CLS] de DistilBERT, 768), concaténées puis passées dans un MLP de classification. Cette fusion intermédiaire est préférée à la fusion précoce (entrées brutes) et à la fusion tardive (moyenne des probabilités), car elle laisse le modèle apprendre des combinaisons croisées tout en restant légère ; les encodeurs sont gelés pour limiter le surapprentissage sur le petit jeu OpenI.

7.2 Comparaison prévue et discussion

- Image seule (modèle supervisé) / texte seul (DistilBERT) / fusion image + texte.
- **Risque de fuite par le texte** : les labels OpenI étant extraits du compte-rendu par mots-clés, un modèle texte seul peut paraître artificiellement performant car le texte « contient » la réponse — biais à signaler dans l'interprétation.

8. Évaluation

8.1 Métriques retenues

Compte tenu du caractère multi-label et déséquilibré, nous privilégions les métriques macro (moyenne non pondérée des classes, qui ne masque pas les pathologies rares) et l'average precision, utilisée aussi comme métrique de sélection. Sont également reportés : AUC, F1, précision, rappel (macro et micro) et hamming loss.

8.2 Résultats globaux comparés (test)

Modèle	AUC macro	AP macro	F1 macro	Seuil
CNN simple	0,670	0,094	0,130	0,55
ResNet18	0,782	0,171	0,207	0,70
ViT-B/16	0,595	0,071	0,110	0,45

Tableau 3 - Comparaison des trois architectures sur le test (meilleur modèle surligné).




Figure 6 - Comparaison des trois modèles (test).

Le ResNet18 domine nettement (AUC macro 0,782) grâce au transfert d'apprentissage. Le CNN entraîné de zéro suit (0,670), et le ViT ferme la marche (0,595), ce qui illustre concrètement qu'un transformeur, gourmand en données et ici entraîné une seule époque, peine sur un petit jeu médical là où un CNN pré-entraîné excelle.

8.3 Résultats par classe / meilleur modèle (ResNet18)

Pathologie	Support	Prév.	AUC	AP	F1	Préc.	Rappel
Atelectasis	2420	10,8 %	0,763	0,269	0,332	0,277	0,416
Cardiomegaly	582	2,6 %	0,879	0,227	0,222	0,133	0,668
Effusion	2754	12,3 %	0,842	0,438	0,384	0,473	0,616
Infiltration	3938	17,6 %	0,675	0,315	0,291	0,402	0,229
Mass	1133	5,1 %	0,743	0,156	0,214	0,155	0,342
Nodule	1335	6,0 %	0,668	0,132	0,167	0,192	0,148
Pneumonia	242	1,1 %	0,704	0,024	0,053	0,029	0,289
Pneumothorax	1089	4,9 %	0,818	0,215	0,296	0,228	0,422
Consolidation	957	4,3 %	0,784	0,134	0,201	0,121	0,587
Edema	413	1,8 %	0,868	0,139	0,164	0,095	0,617
Emphysema	509	2,3 %	0,826	0,108	0,180	0,117	0,385
Fibrosis	362	1,6 %	0,770	0,071	0,102	0,057	0,450
Pleural_Thickening	734	3,3 %	0,723	0,087	0,154	0,101	0,319
Hernia	42	0,2 %	0,885	0,070	0,043	0,023	0,476

Tableau 4 - Métriques par pathologie du ResNet18 (test, 22 433 images).




Figure 7 - Courbes ROC par pathologie (ResNet18, test).




Figure 8 - F1 par pathologie (ResNet18, test).

8.4 Analyse critique des résultats

- **Pathologies bien discriminées** : cardiomégaly (AUC 0,879), œdème (0,868), épanchement (0,842), pneumothorax (0,818), emphyseme (0,826) — signatures

radiologiques marquées. L'épanchement obtient le meilleur F1 (0,384), étant à la fois fréquent et distinctif.

- **Pathologies difficiles** : nodule (AUC 0,668) et infiltrat (0,675), aux frontières floues et à la forte variabilité visuelle.
- **Effet du déséquilibre et du pos_weight** : les classes rares (hernie, œdème, condensation) atteignent un bon rappel (0,48 à 0,59) mais une précision faible — la pondération privilégie la sensibilité au prix de nombreux faux positifs, d'où un F1 macro global modeste (0,207).
- **Comparaison des architectures** : l'écart ResNet18 > CNN > ViT confirme l'intérêt du transfert d'apprentissage et la difficulté du ViT sur peu de données.

9. Suivi expérimental avec MLflow

Toutes les expériences sont tracées avec MLflow (backend SQLite). Deux expériences ont été créées : chestmnist_supervised (3 runs : CNN, ResNet18, ViT) et chestmnist_anomaly (autoencodeur). Pour chaque run sont journalisés hyperparamètres, métriques par époque, métriques finales, seuil optimal et artefacts (checkpoint, figures, CSV).

Le meilleur run, sélectionné sur l'average precision macro, est le ResNet18. Synthèse des runs :

Run	AUC macro	AP macro	F1 macro
chestmnist_resnet18	0,782	0,171	0,207
chestmnist_simple_cnn	0,670	0,094	0,130
chestmnist_vit	0,595	0,071	0,110

Tableau 5 - Synthèse MLflow des runs supervisés (test).

10. Démonstrateur applicatif

Le démonstrateur est une application Streamlit (app/app.py) qui applique exactement la même chaîne de prétraitement qu'à l'entraînement.

10.1 Fonctionnalités

- Téléversement d'une radiographie et sélection du checkpoint supervisé.
- Prédictions multi-label triées, avec le seuil de décision appris et un histogramme des probabilités.
- Score d'anomalie par autoencodeur comparé au seuil appris (décision atypique / non).
- Fusion image + texte lorsqu'un compte-rendu est saisi et que le modèle multimodal est disponible.

- **Appariement automatique du compte-rendu OpenI** via le nom de fichier ou un hachage perceptuel de l'image.

10.2 Cohérence et limites

Le checkpoint embarque sa résolution et son seuil appris, garantissant la cohérence entre modèle entraîné, run MLflow retenu et modèle déployé. Limites : prototype local, non diagnostique.

11. Analyse critique

- **Robustesse et généralisation** : volumétrie et résolution (64 px) limitées ; le ViT, gourmand en données et entraîné une époque, est le plus pénalisé.
- **Déséquilibre** : le `pos_weight` améliore le rappel des classes rares au prix de la précision (faux positifs), d'où un F1 macro modeste.
- **Détection d'anomalies** : l'autoencodeur reste proche du hasard (ROC-AUC 0,485) — l'erreur de reconstruction est un signal faible pour des pathologies localisées et un « normal » hétérogène.
- **Apport de la multimodalité** : à évaluer (brique OpenI), en tenant compte du risque de fuite par le texte.
- **Coût calculatoire** : ViT (224 px) et DistilBERT coûteux ; le gel des encodeurs et les résolutions réduites atténuent la charge.
- **Cohérence du pipeline** : seuil et résolution sérialisés dans le checkpoint, assurant l'alignement entraînement / MLflow / déploiement.

12. Conclusion et perspective

Conclusion : Ce projet met en œuvre un pipeline complet et reproductible de tri radiologique : classification supervisée multi-label sur trois architectures, détection d'anomalies par autoencodeur, démonstrateur applicatif, le tout tracé sous MLflow. Le meilleur modèle est le ResNet18 (AUC macro 0,782 sur le test), qui confirme la supériorité du transfert d'apprentissage ; le CNN de zéro et surtout le ViT restent en retrait. L'autoencodeur, proche du hasard, illustre les limites de la détection d'anomalies par reconstruction sur ce type d'images.

Perspective :

Plusieurs pistes permettraient de prolonger ce travail. La priorité serait de finaliser la brique multimodale image + texte sur OpenI, afin de mener la comparaison entre le modèle image seule, le modèle texte seul et le modèle fusionné. Il serait également pertinent d'entraîner le ViT sur davantage d'époques et à plus haute résolution, pour établir une comparaison équitable avec les autres architectures. Le passage à des jeux de données plus riches et plus réalistes, comme MIMIC-CXR ou CheXpert, accompagné d'un découpage strictement par patient, renforcerait la robustesse et éliminerait tout risque de fuite. Sur le plan de l'interprétabilité, l'ajout de méthodes comme Grad-CAM pour les CNN et la visualisation des cartes d'attention pour le ViT,

ainsi qu'une calibration des probabilités, rendraient les prédictions plus exploitables cliniquement. La détection d'anomalies pourrait être approfondie en testant un autoencodeur variationnel (VAE) et en le comparant à l'autoencodeur convolutif. Enfin, une meilleure extraction des labels textuels, par exemple à l'aide d'un labelliseur de type CheXpert, et une validation externe permettraient d'améliorer la fiabilité de l'ensemble.
